

本文是斯坦福大学CS 229机器学习课程的基础材料, [原始文件下载](#)

翻译: [黄海广](#) 备注: 请关注[github](#)的更新, 近期将更新完。

CS 229 机器学习课程复习材料

一、线性代数复习和参考

1. 基础概念和符号

线性代数提供了一种紧凑地表示和操作线性方程组的方法。例如, 以下方程组:

$$4x_1 - 5x_2 = -13$$

$$-2x_1 + 3x_2 = 9$$

这是两个方程和两个变量, 正如你从高中代数中所知, 你可以找到 x_1 和 x_2 的唯一解 (除非方程以某种方式退化, 例如, 如果第二个方程只是第一个的倍数, 但在上面的情况下, 实际上只有一个唯一解)。在矩阵表示法中, 我们可以更紧凑地表达:

$$Ax = b$$

$$\text{with } A = \begin{bmatrix} 4 & -5 \\ -2 & 3 \end{bmatrix}, b = \begin{bmatrix} 13 \\ -9 \end{bmatrix}$$

我们可以看到, 这种形式的线性方程有许多优点 (比如明显地节省空间)。

1.1 基本符号

我们使用以下符号:

- $A \in \mathbb{R}^{m \times n}$, 表示 A 为由实数组成具有 m 行和 n 列的矩阵。
- $x \in \mathbb{R}^n$, 表示具有 n 个元素的向量。通常, 向量 x 将表示列向量: 即, 具有 n 行和1列的矩阵。如果我们想要明确地表示行向量: 具有1行和 n 列的矩阵 - 我们通常写 x^T (这里 x^T 是 x 的转置)。
- x_i 表示向量 x 的第 i 个元素

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$

- 我们使用符号 a_{ij} (或 $A_{ij}, A_{i,j}, A_{ij}, A_i, j$ 等) 来表示第 i 行和第 j 列中的 A 的元素:

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}$$

- 我们用 a^j 或者 $A_{:,j}$ 表示矩阵 A 的第 j 列:

$$A = \begin{bmatrix} | & | & & | \\ a^1 & a^2 & \cdots & a^n \\ | & | & & | \end{bmatrix}$$

- 我们用 a^T 或者 $A_{i,:}$ 表示矩阵 A 的第 i 行:

$$A = \begin{bmatrix} -a_1^T - \\ -a_2^T - \\ \vdots \\ -a_m^T - \end{bmatrix}$$

- 在许多情况下, 将矩阵视为列向量或行向量的集合非常重要且方便。通常, 在向量而不是标量上操作在数学上(和概念上)更清晰。用于矩阵的列或行的表示并没有通用约定, 因此只要明确定义了符号。

2. 矩阵乘法

两个矩阵相乘, 其中 $A \in \mathbb{R}^{m \times n}$ and $B \in \mathbb{R}^{n \times p}$, 则:

$$C = AB \in \mathbb{R}^{m \times p}$$

其中:

$$C_{ij} = \sum_{k=1}^n A_{ik} B_{kj}$$

请注意, 为了使矩阵乘积存在, A 中的列数必须等于 B 中的行数。有很多方法可以查看矩阵乘法, 我们将从检查一些特殊情况开始。

2.1 向量-向量乘法

给定两个向量 $x, y \in \mathbb{R}^n$, $x^T y$ 通常称为**向量内积**或者**点积**, 结果是个**实数**。

$$x^T y \in \mathbb{R} = [x_1 \quad x_2 \quad \cdots \quad x_n] \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \sum_{i=1}^n x_i y_i$$

注意: $x^T y = y^T x$ 始终成立。

给定向量 $x \in \mathbb{R}^m$, $y \in \mathbb{R}^n$ (他们的尺寸是否相同都没关系), $xy^T \in \mathbb{R}^{m \times n}$ 叫做**向量外积**, 当 $(xy^T)_{ij} = x_i y_j$ 的时候, 它是一个矩阵。

$$xy^T \in \mathbb{R}^{m \times n} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix} [y_1 \quad y_2 \quad \cdots \quad y_n] = \begin{bmatrix} x_1 y_1 & x_1 y_2 & \cdots & x_1 y_n \\ x_2 y_1 & x_2 y_2 & \cdots & x_2 y_n \\ \vdots & \vdots & \ddots & \vdots \\ x_m y_1 & x_m y_2 & \cdots & x_m y_n \end{bmatrix}$$

举一个外积如何使用的一个例子, 让 $\mathbf{1} \in \mathbb{R}^n$ 表示一个 n 维向量, 其元素都等于1, 此外, 考虑矩阵 $A \in \mathbb{R}^{m \times n}$, 其列全部等于某个向量 $x \in \mathbb{R}^m$ 。我们可以使用外积紧凑地表示矩阵 A :

$$A = \begin{bmatrix} | & | & & | \\ x & x & \cdots & x \\ | & | & & | \end{bmatrix} = \begin{bmatrix} x_1 & x_1 & \cdots & x_1 \\ x_2 & x_2 & \cdots & x_2 \\ \vdots & \vdots & \ddots & \vdots \\ x_m & x_m & \cdots & x_m \end{bmatrix} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix} [1 \quad 1 \quad \cdots \quad 1] = x \mathbf{1}^T$$

2.2 矩阵-向量乘法

给定矩阵 $A \in \mathbb{R}^{m \times n}$ ，向量 $x \in \mathbb{R}^n$ ，它们的积是一个向量 $y = Ax \in \mathbb{R}^m$ 。有几种方法可以查看矩阵向量乘法，我们将依次查看它们中的每一种。

如果我们按行写 A ，那么我们可以表示 Ax 为：

$$y = Ax = \begin{bmatrix} - & a_1^T & - \\ - & a_2^T & - \\ & \vdots & \\ - & a_m^T & - \end{bmatrix} x = \begin{bmatrix} a_1^T x \\ a_2^T x \\ \vdots \\ a_m^T x \end{bmatrix}$$

换句话说，第 i 个 y 是 A 的第 i 行和 x 的内积，即： $y_i = y_i = a_i^T x$ 。

同样的，可以把 A 写成列的方式，则公式如下：

$$y = Ax = \begin{bmatrix} | & | & & | \\ a^1 & a^2 & \cdots & a^n \\ | & | & & | \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} a^1 \end{bmatrix} x_1 + \begin{bmatrix} a^2 \end{bmatrix} x_2 + \cdots + \begin{bmatrix} a^n \end{bmatrix} x_n$$

换句话说， y 是 A 的列的线性组合，其中线性组合的系数由 x 的条目给出。

到目前为止，我们一直在右侧乘以列向量，但也可以在左侧乘以行向量。这是写的， $y^T = x^T A$ 表示 $A \in \mathbb{R}^{m \times n}$ ， $x \in \mathbb{R}^m$ ， $y \in \mathbb{R}^n$ 。和以前一样，我们可以用两种可行的方式表达 y^T ，这取决于我们是否根据行或列表达 A 。

第一种情况，我们把 A 用列表示：

$$y^T = x^T A = x^T \begin{bmatrix} | & | & & | \\ a^1 & a^2 & \cdots & a^n \\ | & | & & | \end{bmatrix} = [x^T a^1 \quad x^T a^2 \quad \cdots \quad x^T a^n]$$

这表明 y^T 的第 i 个条目等于 x 和 A 的第 i 列的内积。

最后，根据行表示 A ，我们得到了向量-矩阵乘积的最终表示：

$$y^T = x^T A = [x_1 \quad x_2 \quad \cdots \quad x_n] \begin{bmatrix} -a_1^T- \\ -a_2^T- \\ \vdots \\ -a_m^T- \end{bmatrix} = x_1 [-a_1^T-] + x_2 [-a_2^T-] + \cdots + x_n [-a_n^T-]$$

所以我们看到 y^T 是 A 的行的线性组合，其中线性组合的系数由 x 的条目给出。

2.3 矩阵-矩阵乘法

有了这些知识，我们现在可以看看四种不同的（形式不同，但结果是相同的）矩阵-矩阵乘法：也就是本节开头所定义的 $C = AB$ 的乘法。

首先，我们可以将矩阵-矩阵乘法视为一组向量-向量乘积。从定义中可以得出：的最明显的观点是 C 的 (i, j) 条目等于 A 的第 i 行和 B 的第 j 列的内积。如下面的公式所示：

$$C = AB = \begin{bmatrix} - & a_1^T & - \\ - & a_2^T & - \\ & \vdots & \\ - & a_m^T & - \end{bmatrix} \begin{bmatrix} | & | & & | \\ b_1 & b_2 & \cdots & b_p \\ | & | & & | \end{bmatrix} = \begin{bmatrix} a_1^T b_1 & a_1^T b_2 & \cdots & a_1^T b_p \\ a_2^T b_1 & a_2^T b_2 & \cdots & a_2^T b_p \\ \vdots & \vdots & \ddots & \vdots \\ a_m^T b_1 & a_m^T b_2 & \cdots & a_m^T b_p \end{bmatrix}$$

这里的 $A \in \mathbb{R}^{m \times n}$, $B \in \mathbb{R}^{n \times p}$, $a_i \in \mathbb{R}^n$, $b^j \in \mathbb{R}^{n \times p}$, 这里的 $A \in \mathbb{R}^{m \times n}$, $B \in \mathbb{R}^{n \times p}$, $a_i \in \mathbb{R}^n$, $b^j \in \mathbb{R}^{n \times p}$, 所以它们可以计算内积。我们用通常用行表示 A 而用列表示 B 时。或者, 我们可以用列表表示 A , 用行表示 B , 这时 AB 是求外积的和。公式如下:

$$C = AB = \begin{bmatrix} | & | & \cdots & | \\ a_1 & a_2 & \cdots & a_n \\ | & | & \cdots & | \end{bmatrix} \begin{bmatrix} - & b_1^T & - \\ - & b_2^T & - \\ \vdots & \vdots & \vdots \\ - & b_n^T & - \end{bmatrix} = \sum_{i=1}^n a_i b_i^T$$

换句话说, AB 等于所有的 A 的第 i 列和 B 第 i 行的外积的和。因此, 在这种情况下, $a_i \in \mathbb{R}^m$ 和 $b_i \in \mathbb{R}^p$, 外积 $a_i b_i^T$ 的维度是 $m \times p$, 与 C 的维度一致。

其次, 我们还可以将矩阵 - 矩阵乘法视为一组矩阵向量积。如果我们把 B 用列表示, 我们可以将 C 的列视为 A 和 B 的列的矩阵向量积。公式如下:

$$C = AB = A \begin{bmatrix} | & | & \cdots & | \\ b_1 & b_2 & \cdots & b_p \\ | & | & \cdots & | \end{bmatrix} = \begin{bmatrix} | & | & \cdots & | \\ Ab_1 & Ab_2 & \cdots & Ab_p \\ | & | & \cdots & | \end{bmatrix}$$

这里 C 的第 i 列由矩阵向量乘积给出, 右边的向量为 $c_i = Ab_i$ 。这些矩阵向量乘积可以使用前一小节中给出的两个观点来解释。最后, 我们有类似的观点, 我们用行表示 A , C 的行作为 A 和 C 行之间的矩阵向量积。公式如下:

$$C = AB = \begin{bmatrix} - & a_1^T & - \\ - & a_2^T & - \\ \vdots & \vdots & \vdots \\ - & a_m^T & - \end{bmatrix} B = \begin{bmatrix} - & a_1^T B & - \\ - & a_2^T B & - \\ \vdots & \vdots & \vdots \\ - & a_m^T B & - \end{bmatrix}$$

这里第 i 行的 C 由左边的向量的矩阵向量乘积给出: $c_i^T = a_i^T B$

将矩阵乘法剖析到如此大的程度似乎有点过分, 特别是当所有这些观点都紧跟我们在本节开头给出的初始定义 (在一行数学中) 之后。

这些不同方法的直接优势在于它们允许您在向量的级别/单位而不是标量上进行操作。为了完全理解线性代数而不会迷失在复杂的索引操作中, 关键是要用尽可能多的概念进行操作。

实际上所有的线性代数都处理某种矩阵乘法, 花一些时间对这里提出的观点进行直观的理解是非常必要的。

除此之外, 了解一些更高级别的矩阵乘法的基本属性是很有必要的:

- 矩阵乘法交换律: $(AB)C = A(BC)$
- 矩阵乘法分配律: $A(B + C) = AB + AC$
- 矩阵乘法通常不是可交换的; 也就是说, 通常 $AB \neq BA$ 。(例如, 假设 $A \in \mathbb{R}^{m \times n}$, $B \in \mathbb{R}^{n \times p}$, 如果 m 和 p 不相等, 矩阵乘积 BA 甚至不存在!)

如果您不熟悉这些属性, 请花点时间自己验证它们。例如, 为了检查矩阵乘法的相关性, 假设 $A \in \mathbb{R}^{m \times n}$, $B \in \mathbb{R}^{n \times p}$, $C \in \mathbb{R}^{p \times q}$ 。注意 $AB \in \mathbb{R}^{m \times p}$, 所以 $(AB)C \in \mathbb{R}^{m \times q}$ 。类似地, $BC \in \mathbb{R}^{n \times q}$, 所以 $A(BC) \in \mathbb{R}^{m \times q}$ 。因此, 所得矩阵的维度一致。为了表明矩阵乘法是相关的, 足以检查 $(AB)C$ 的第 (i, j) 个元素是否等于 $A(BC)$ 的第 (i, j) 个条目。我们可以使用矩阵乘法的定义直接验证这一点:

$$\begin{aligned}
((AB)C)_{ij} &= \sum_{k=1}^p (AB)_{ik} C_{kj} = \sum_{k=1}^p \left(\sum_{l=1}^n A_{il} B_{lk} \right) C_{kj} \\
&= \sum_{k=1}^p \left(\sum_{l=1}^n A_{il} B_{lk} C_{kj} \right) = \sum_{l=1}^n \left(\sum_{k=1}^p A_{il} B_{lk} C_{kj} \right) \\
&= \sum_{l=1}^n A_{il} \left(\sum_{k=1}^p B_{lk} C_{kj} \right) = \sum_{l=1}^n A_{il} (BC)_{lj} = (A(BC))_{ij}
\end{aligned}$$

3 运算和属性

在本节中，我们介绍矩阵和向量的几种运算和属性。希望能够为您复习大量此类内容，这些笔记可以作为这些主题的参考。

3.1 单位矩阵和对角矩阵

单位矩阵, $I \in \mathbb{R}^{n \times n}$ ，它是一个方阵，对角线的元素是1，其余元素都是0：

$$I_{ij} = \begin{cases} 1 & i = j \\ 0 & i \neq j \end{cases}$$

对于所有 $A \in \mathbb{R}^{m \times n}$ ，有：

$$AI = A = IA$$

注意，在某种意义上，单位矩阵的表示法是不明确的，因为它没有指定 I 的维数。通常， I 的维数是从上下文推断出来的，以便使矩阵乘法成为可能。例如，在上面的等式中， $AI = A$ 中的 I 是 $n \times n$ 矩阵，而 $A = IA$ 中的 I 是 $m \times m$ 矩阵。

对角矩阵是一种这样的矩阵：对角线之外的元素全为0。对角阵通常表示为： $D = \text{diag}(d_1, d_2, \dots, d_n)$ ，其中：

$$D_{ij} = \begin{cases} d_i & i = j \\ 0 & i \neq j \end{cases}$$

很明显：单位矩阵 $I = \text{diag}(1, 1, \dots, 1)$ 。

3.2 转置

矩阵的转置是指翻转矩阵的行和列。

给定一个矩阵：

$A \in \mathbb{R}^{m \times n}$ ，它的转置为 $n \times m$ 的矩阵 $A^T \in \mathbb{R}^{n \times m}$ ，其中的元素为：

$$(A^T)_{ij} = A_{ji}$$

事实上，我们在描述行向量时已经使用了转置，因为列向量的转置自然是行向量。

转置的以下属性很容易验证：

- $(A^T)^T = A$
- $(AB)^T = B^T A^T$
- $(A + B)^T = A^T + B^T$

3.3 对称矩阵

如果 $A = A^T$ ，则矩阵 $A \in \mathbb{R}^{n \times n}$ 是对称矩阵。如果 $A = -A^T$ ，它是反对称的。很容易证明，对于任何矩阵 $A \in \mathbb{R}^{n \times n}$ ，矩阵 $A + A^T$ 是对称的，矩阵 $A - A^T$ 是反对称的。由此得出，任何方阵 $A \in \mathbb{R}^{n \times n}$ 可以表示为对称矩阵和反对称矩阵的和，所以：

$$A = \frac{1}{2}(A + A^T) + \frac{1}{2}(A - A^T)$$

上面公式的右边的第一个矩阵是对称矩阵，而第二个矩阵是反对称矩阵。事实证明，对称矩阵在实践中用到很多，它们有很多很好的属性，我们很快就会看到它们。通常将大小为 n 的所有对称矩阵的集合表示为 \mathbb{S}^n ，因此 $A \in \mathbb{S}^n$ 意味着 A 是对称的 $n \times n$ 矩阵；

3.4 矩阵的迹

方阵 $A \in \mathbb{R}^{n \times n}$ 的迹，表示为 $\text{tr}(A)$ （或者只是 $\text{tr } A$ ，如果括号显然是隐含的），是矩阵中对角元素的总和：

$$\text{tr } A = \sum_{i=1}^n A_{ii}$$

如CS229讲义中所述，迹具有以下属性（如下所示）：

- 对于矩阵 $A \in \mathbb{R}^{n \times n}$ ，则： $\text{tr } A = \text{tr } A^T$
- 对于矩阵 $A, B \in \mathbb{R}^{n \times n}$ ，则： $\text{tr}(A + B) = \text{tr } A + \text{tr } B$
- 对于矩阵 $A \in \mathbb{R}^{n \times n}, t \in \mathbb{R}$ ，则： $\text{tr}(tA) = t \text{tr } A$ 。
- 对于矩阵 A, B ， AB 为方阵，则： $\text{tr } AB = \text{tr } BA$
- 对于矩阵 A, B, C ， ABC 为方阵，则： $\text{tr } ABC = \text{tr } BCA = \text{tr } CAB$ ，同理，更多矩阵的积也是有这个性质。

$$\begin{aligned} \text{tr } AB &= \sum_{i=1}^m (AB)_{ii} = \sum_{i=1}^m \left(\sum_{j=1}^n A_{ij} B_{ji} \right) \\ &= \sum_{i=1}^m \sum_{j=1}^n A_{ij} B_{ji} = \sum_{j=1}^n \sum_{i=1}^m B_{ji} A_{ij} \\ &= \sum_{j=1}^n \left(\sum_{i=1}^m B_{ji} A_{ij} \right) = \sum_{j=1}^n (BA)_{jj} = \text{tr } BA \end{aligned}$$

这里，第一个和最后两个等式使用迹运算符和矩阵乘法的定义，重点在第四个等式，使用标量乘法的可交换性来反转每个乘积中的项的顺序，以及标量加法的可交换性和相关性，以便重新排列求和的顺序。

3.5 范数

向量的范数 $\|x\|$ 是非正式度量的向量的“长度”。例如，我们有常用的欧几里德或 ℓ_2 范数，

$$\|x\|_2 = \sqrt{\sum_{i=1}^n x_i^2}$$

注意： $\|x\|_2^2 = x^T x$

更正式地，范数是满足4个属性的函数（ $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ）：

1. 对于所有的 $x \in \mathbb{R}^n$ ， $f(x) \geq 0$ （非负）。
2. 当且仅当 $x = 0$ 时， $f(x) = 0$ （明确性）。
3. 对于所有 $x \in \mathbb{R}^n, t \in \mathbb{R}$ ，则 $f(tx) = |t| f(x)$ （正齐次性）。
4. 对于所有 $x, y \in \mathbb{R}^n$ ， $f(x + y) \leq f(x) + f(y)$ （三角不等式）

其他范数的例子是 ℓ_1 范数：

$$\|x\|_1 = \sum_{i=1}^n |x_i|$$

和 ℓ_∞ 范数：

$$\|x\|_{\infty} = \max_i |x_i|$$

事实上，到目前为止所提出的所有三个范数都是 ℓ_p 范数族的例子，它们由实数 $p \geq 1$ 参数化，并定义为：

$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}$$

也可以为矩阵定义范数，例如Frobenius范数：

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n A_{ij}^2} = \sqrt{\text{tr}(A^T A)}$$

许多其他更多的范数，但它们超出了这个复习材料的范围。

后面部分还在翻译中，请关注[github](#)的更新，近期将更新完。